

Descarga y consolidacion de datos

Construir la base real y trazable de todo el pipeline

Idea central: Construir la base real y trazable de todo el pipeline

Fuente revisada: notebooks/00_descarga_datos.ipynb

Fuentes y universos

Se combinan cierres diarios ajustados de Norgate con barras OHLCV de 5 minutos de EODHD. Los datos diarios terminan el 29-05-2026; el intradia descargado cubre como maximo 02-11-2020 a 28-08-2026, aunque no todos los bancos empiezan el mismo día.

Universo	Tamaño	Requisito	Uso
Predictor	25	Historia diaria densa desde 1990	Target y ventanas supervisadas
Generadores	150 candidatos	Cobertura intradia suficiente	Pool real amplio para aprender la distribucion

Por que dos universos

Exigir 36 años de historia diaria a los generadores reduciría innecesariamente el numero de bancos. Los 25 del predictor necesitan continuidad; los generadores necesitan muchas sesiones recientes y pueden aceptar altas, bajas y coberturas parciales.

Transformaciones

- Retorno diario: diferencia del logaritmo del cierre ajustado.
- Volatilidad realizada: raiz de la suma de retornos de 5 minutos al cuadrado.
- Retornos de los primeros y ultimos 30 minutos, rango high-low y numero de barras.
- Cruce por ticker y fecha entre retorno Norgate y features EODHD.

Dimensiones verificadas

Objeto	Dimension	Periodo / observacion
Retornos predictor	7.865 x 25	03-01-1990 a 29-05-2026; matriz densa
Retornos generador	1.399 x 150	02-11-2020 a 29-05-2026; 5,3% NaN medio
Features intradia	208.386 filas	149 tickers; 02-11-2020 a 28-08-2026
Pool condicional	141.065 x 5	149 tickers; 03-11-2020 a 29-05-2026

Controles de calidad

- Una sesion necesita al menos 40 barras y un ticker al menos 60 sesiones validas.
- 149 de 150 candidatos superan el filtro; la cobertura por banco sigue siendo desigual.
- Se eliminan NaN e infinitos al cruzar retorno y features y se aplican limites de cordura.
- El pool final conserva metadata de ticker y fecha para permitir el corte temporal posterior.

Salidas

Archivo	Contenido
returns_predictor.parquet	Retornos reales de los 25 bancos
returns_generator.parquet	Retornos del universo amplio
intraday_features_real.parquet	Features reales por ticker y sesion
conditional_pool.npy + metadata	Matriz de cinco variables y trazabilidad temporal

Cambio clave: se aprovecha la historia real desde 2020-11; ya no se sintetizan años para los que existen barras reales.

Lectura critica

La expresion '5,5 años reales' describe la cobertura maxima, no una matriz uniforme de 150 bancos. La fecha 02-11-2020 es la primera observada en la descarga; 135 candidatos empiezan ese día y 15 mas tarde. Ademas, las barras posteriores al 29-05-2026 no entran en el predictor porque Norgate termina ahi.

Conexion con el notebook 01

El EDA comprueba si las variables intradia contienen estructura propia y si merece la pena reconstruirlas para el periodo historico sin barras de 5 minutos.